

# Laboratório 5 - Identificação e Controle Adaptativo de Sistemas - Estimador de Mínimos Quadrados Recursivo (MQR)

Geovanne Almeida de Oliveira

03/06/2026

## 1 Identificação da Atividade

O presente trabalho tem como propósito explorar a aplicação do método dos Mínimos Quadrados Recursivo (MQR) na identificação online de sistemas dinâmicos discretos. Diferentemente do estimador estudado no Laboratório 4, o MQR atualiza os parâmetros do modelo a cada nova amostra disponível, sem necessidade de armazenar todo o histórico de dados ou recalcular a inversão matricial do início. Essa característica o torna adequado tanto para aplicações em tempo real quanto para o rastreamento de plantas com parâmetros variantes no tempo.

O estudo é conduzido em três frentes complementares. A primeira parte aplica o MQR a dados experimentais de um sistema de primeira ordem desconhecido, avaliando a influência do parâmetro de inicialização  $\rho$  sobre a velocidade e a qualidade da convergência. A segunda parte realiza um ensaio prático com um filtro passa-baixa Sallen-Key físico, identificando um modelo de segunda ordem a partir de dados coletados com Arduino Mega e Octave. A terceira parte avalia o desempenho do estimador MQR em um cenário de rastreamento de planta variante no tempo, comparando a versão padrão com estratégias de reinicialização da matriz  $P(n)$  e fator de esquecimento  $\lambda$ .

## 2 Identificação via Mínimos Quadrados Recursivo: Dados Experimentais

### 2.1 Formulação do Algoritmo MQR

Considera-se a função de transferência discreta de primeira ordem:

$$G(z) = \frac{b_1 z^{-1}}{1 + a_1 z^{-1}} \quad (1)$$

Cuja equação a diferenças correspondente é:

$$y(n) = b_1 x(n-1) - a_1 y(n-1) = u^T(n) \theta \quad (2)$$

Com o vetor de regressores e o vetor de parâmetros definidos por:

$$u(n) = \begin{bmatrix} x(n-1) \\ -y(n-1) \end{bmatrix}, \quad \theta = \begin{bmatrix} b_1 \\ a_1 \end{bmatrix} \quad (3)$$

A versão recursiva do estimador evita a inversão da matriz de regressores a cada iteração. Dado um estimado  $\hat{\theta}(n-1)$ , a atualização no instante  $n$  é realizada pelas seguintes equações:

$$h(n) = \frac{P(n-1) u(n)}{1 + u^T(n) P(n-1) u(n)} \quad (4)$$

$$\hat{\theta}(n) = \hat{\theta}(n-1) + h(n) \left[ y(n) - u^T(n) \hat{\theta}(n-1) \right] \quad (5)$$

$$P(n) = [I - h(n) u^T(n)] P(n-1) \quad (6)$$

onde  $P(n)$  é a matriz de covariância do erro de estimação e  $h(n)$  é o vetor de ganho. As condições iniciais são  $\hat{\theta}(0) = 0$  e  $P(0) = \rho I$ , sendo  $\rho > 0$  um escalar de inicialização que controla a confiança inicial nos parâmetros.

## 2.2 Configuração do Experimento

Os dados utilizados provêm do arquivo `mqr_sistema_1.mat`, que contém  $N = 280$  amostras da entrada  $x(n)$  e da saída  $y(n)$ , coletadas com frequência de amostragem  $f_s = 40$  Hz (período  $T_s = 25$  ms, duração total de 7 s). A implementação seguiu o código-base `LAB5a.m`, adaptado para quatro valores de  $\rho$ : 0,1; 1; 10 e 100.

## 2.3 Influência do Parâmetro $\rho$

O parâmetro  $\rho$  define a magnitude inicial de  $P(0) = \rho I$ . Um valor grande de  $\rho$  indica alta incerteza inicial nos parâmetros, de modo que o algoritmo atribui maior peso às novas amostras e converge mais rapidamente, embora possa apresentar oscilações transitórias. Um valor pequeno de  $\rho$ , por sua vez, implica alta confiança nos valores iniciais (nulos), o que retarda a convergência.

A Figura 1 apresenta as curvas de evolução de  $\hat{b}_1(n)$  e  $\hat{a}_1(n)$  ao longo do tempo para os quatro valores de  $\rho$  testados. Observa-se claramente que para  $\rho = 0,1$  a convergência é lenta e os parâmetros ainda não atingiram o regime permanente ao final do ensaio, ao passo que para  $\rho \geq 10$  a estabilização ocorre rapidamente nas primeiras frações de segundo.




Figura 1: Evolução dos parâmetros estimados  $\hat{b}_1$  e  $\hat{a}_1$  para diferentes valores de  $\rho$ .

Os valores estimados em regime permanente (última amostra,  $n = 280$ ) para cada  $\rho$  estão resumidos na Tabela 1.

| $\rho$ | $\hat{b}_1$ | $\hat{a}_1$ |
|--------|-------------|-------------|
| 0,1    | 0,0589      | -0,4908     |
| 1      | 0,0608      | -0,8696     |
| 10     | 0,0609      | -0,9424     |
| 100    | 0,0610      | -0,9503     |

Tabela 1: Parâmetros estimados em regime permanente para diferentes valores de  $\rho$ .

Nota-se que  $\hat{b}_1$  converge para aproximadamente 0,0610 em todos os casos com  $\rho \geq 1$ , enquanto  $\hat{a}_1$  se aproxima de -0,9503 à medida que  $\rho$  cresce. Esse comportamento é esperado: valores maiores de  $\rho$  permitem que o algoritmo explore melhor o espaço de parâmetros, produzindo estimativas mais próximas das obtidas pelo estimador com todas as amostras. O valor  $\rho = 100$  é adotado como referência para a etapa de validação, por apresentar a melhor convergência.

A função de transferência identificada com  $\rho = 100$  é:

$$\hat{G}(z) = \frac{0,0610 z^{-1}}{1 - 0,9503 z^{-1}} \quad (7)$$

O polo em  $z = 0,9503$  indica uma dinâmica lenta, compatível com um sistema de primeira ordem com constante de tempo relativamente elevada em relação ao período de amostragem.

## 2.4 Validação do Modelo

Para verificar a qualidade da identificação, a saída estimada  $\hat{y}(n)$  foi calculada simulando o modelo (7) com a entrada experimental  $x(n)$ . A Figura 2 compara  $y(n)$  e  $\hat{y}(n)$  para  $\rho = 0.1$ ,  $\rho = 1$ ,  $\rho = 10$  e  $\rho = 100$ .




Figura 2: Comparação entre saída real  $y(n)$  e saída estimada  $\hat{y}(n)$  para diferentes valores de  $\rho$ .

Nota-se que para o menor  $\rho$  a saída estimada ficou extremamente descaracterizada, denotando ainda mais a importância de escolher um valor adequado para  $\rho$ . Como esperado, a aderência entre as curvas aumenta de acordo com o crescimento do valor de  $\rho$ , entretanto, para valores muito altos do parâmetro, essa diferença diminui cada vez mais.

Com isso, pode-se confirmar que o modelo de primeira ordem identificado representa adequadamente o comportamento dinâmico do sistema. O modelo com  $\rho = 100$  apresenta ligeiramente melhor ajuste ao longo de todo o horizonte temporal, o que é consistente com a maior precisão dos parâmetros estimados nessa condição.

## 3 Ensaio Prático – Filtro Passa-Baixa Sallen-Key

### 3.1 Descrição do Experimento

O experimento consistiu na identificação paramétrica de um sistema físico real representado por um filtro passa-baixa com topologia Sallen-Key, cujo circuito é ilustrado na Figura 3. O circuito contém dois comutadores (SW1 e SW2) que alteram os componentes do filtro em instantes pré-determinados, introduzindo mudanças na dinâmica do sistema durante o ensaio.




Figura 3: Filtro passa-baixa com topologia Sallen-Key.

A aquisição dos dados foi realizada excitando o sistema com um sinal de onda quadrada de 2 Hz, por meio da plataforma de ensaio composta pelo microcontrolador Arduino Mega em conjunto com o software Octave. Os dados foram armazenados no arquivo `ensaio_lab5_rls.mat`, contendo  $N = 500$  amostras da entrada  $u(n)$  e da saída  $y(n)$ , coletadas com frequência de amostragem  $f_s = 10$  Hz ( $T_s = 0,1$  s, duração total de 50 s). A implementação seguiu o código-base `LAB5b.m`.

### 3.2 Modelo de Segunda Ordem

O modelo discreto adotado para o filtro é de segunda ordem, com função de transferência:

$$G(z) = \frac{b_1 z^{-1} + b_2 z^{-2}}{1 + a_1 z^{-1} + a_2 z^{-2}} \quad (8)$$

cuja equação a diferenças é  $y(n) = b_1 u(n-1) + b_2 u(n-2) - a_1 y(n-1) - a_2 y(n-2)$ . O vetor de regressores e o vetor de parâmetros são, respectivamente:

$$u(n) = \begin{bmatrix} u(n-1) \\ u(n-2) \\ -y(n-1) \\ -y(n-2) \end{bmatrix}, \quad \theta = \begin{bmatrix} b_1 \\ b_2 \\ a_1 \\ a_2 \end{bmatrix} \quad (9)$$

Como o sistema possui dinâmica variante no tempo (em virtude dos comutadores), o estimador MQR foi executado com fator de esquecimento  $\lambda = 0,95$  e parâmetro de inicialização  $\rho = 500$ , de modo que a matriz  $P$  não degenere a zero e o algoritmo mantenha capacidade de rastreamento ao longo de todo o ensaio. As equações do MQR com fator de esquecimento são:

$$h(n) = \frac{P(n-1) u(n)}{\lambda + u^T(n) P(n-1) u(n)} \quad (10)$$

$$P(n) = \frac{1}{\lambda} [I - h(n) u^T(n)] P(n-1) \quad (11)$$

### 3.3 Evolução dos Parâmetros Estimados

A Figura 4 apresenta a evolução temporal dos quatro parâmetros estimados ao longo dos 50s de ensaio. As linhas tracejadas verticais indicam os instantes aproximados de acionamento dos comutadores 1 ( $t \approx 17$ s) e 2 ( $t \approx 32$ s), evidenciando as mudanças na dinâmica que o estimador deve rastrear em tempo real.




Figura 4: Evolução temporal dos parâmetros estimados ( $\rho = 500$ ,  $\lambda = 0,95$ ). Linhas verticais tracejadas indicam os instantes de chaveamento 1 ( $t \approx 17$ s) e 2 ( $t \approx 32$ s).

Observa-se que o estimador converge rapidamente no primeiro regime e, a cada acionamento de comutador, os parâmetros sofrem transições visíveis e reconvergem para novos valores em regime permanente. Esse comportamento confirma que o fator de esquecimento  $\lambda = 0,95$  é suficiente para manter a matriz  $P$  com norma não nula, garantindo a capacidade de adaptação mesmo após longos períodos de operação estacionária.

Os parâmetros estimados em regime permanente para cada um dos três intervalos de operação estão resumidos na Tabela 2.

Tabela 2: Parâmetros identificados em cada regime operacional do filtro Sallen-Key.

| Regime                               | $\hat{b}_1$ | $\hat{b}_2$ | $\hat{a}_1$ | $\hat{a}_2$ |
|--------------------------------------|-------------|-------------|-------------|-------------|
| $t < 17$ s                           | 0,0278      | 0,1639      | -1,5753     | 0,6977      |
| $17 \text{ s} \leq t < 32 \text{ s}$ | 0,0362      | 0,3304      | -1,5303     | 0,7641      |
| $t \geq 32 \text{ s}$                | -0,0232     | 0,5205      | -1,1529     | 0,4698      |

A variação clara nos coeficientes entre os três regimes, em especial o aumento progressivo de  $\hat{b}_2$  e a redução de  $\hat{a}_1$  e  $\hat{a}_2$ , confirma que os comutadores alteram efetivamente a dinâmica do filtro.

### 3.4 Validação do Modelo

A saída estimada  $\hat{y}(n)$  foi obtida propagando o modelo com os parâmetros  $\hat{\theta}(n)$  atualizados dinamicamente a cada instante, de modo que a validação reflita o desempenho do estimador em modo de rastreamento contínuo. A Figura 5 compara  $y(n)$  e  $\hat{y}(n)$  ao longo de todo o ensaio.




Figura 5: Comparação entre saída medida  $y(n)$  e saída estimada  $\hat{y}(n)$  ao longo dos 50 s de ensaio.

A aderência entre as duas curvas, no primeiro setor, é pouco satisfatória, contudo, ao passar do tempo a aderência melhora consideravelmente, chegando a um grau aceitável para o experimento. A qualidade do ajuste confirma que o modelo de segunda ordem com fator de esquecimento é adequado para representar o comportamento dinâmico variante do filtro Sallen-Key.

## 4 Atividade 3 – Rastreamento de Planta Variante no Tempo

### 4.1 Metodologia

Nesta atividade, avalia-se o desempenho do estimador MQR em um cenário de rastreamento de uma planta variante no tempo. Considera-se uma planta contínua de segunda ordem com função de transferência dada por

$$G(s) = \frac{K(t) \omega_n^2(t)}{s^2 + 2\xi(t) \omega_n(t) s + \omega_n^2(t)}, \quad (12)$$

em que o ganho  $K(t)$ , a constante de amortecimento  $\xi(t)$  e a frequência natural  $\omega_n(t)$  sofrem variação abrupta em  $t = 10$  s, conforme

$$K(t) = \begin{cases} 1,00, & t < 10 \text{ s} \\ 0,95, & t \geq 10 \text{ s} \end{cases}, \quad \xi(t) = \begin{cases} 0,7, & t < 10 \text{ s} \\ 0,6, & t \geq 10 \text{ s} \end{cases}, \quad \omega_n(t) = \begin{cases} 20 \text{ rad/s}, & t < 10 \text{ s} \\ 19 \text{ rad/s}, & t \geq 10 \text{ s} \end{cases}. \quad (13)$$

A planta contínua é discretizada pelo método da invariância ao degrau com período de amostragem  $T = 0,1$  s ( $f_s = 10$  Hz), resultando em uma função de transferência discreta de segunda ordem da forma

$$G(z) = \frac{b_1 z^{-1} + b_2 z^{-2}}{1 + a_1 z^{-1} + a_2 z^{-2}}, \quad (14)$$

cujas equações de diferenças correspondente é

$$y(n) = b_1 x(n-1) + b_2 x(n-2) - a_1 y(n-1) - a_2 y(n-2). \quad (15)$$

O sistema é excitado por um sinal de onda quadrada de 2 Hz com ciclo de trabalho de 50%, durante um total de 20 s. O vetor de regressores e o vetor de parâmetros a estimar são definidos como

$$u(n) = \begin{bmatrix} x(n-1) \\ x(n-2) \\ -y(n-1) \\ -y(n-2) \end{bmatrix}, \quad \theta = \begin{bmatrix} b_1 \\ b_2 \\ a_1 \\ a_2 \end{bmatrix}. \quad (16)$$

O desempenho do estimador é avaliado por meio de três metodologias distintas, descritas a seguir.

#### 4.1.1 MQR Padrão

No MQR padrão, as equações de atualização são as usuais, com condições iniciais  $\hat{\theta}(0) = 0$  e  $P(0) = \rho I$ , com  $\rho = 100$ . O ganho de estimação, a atualização dos parâmetros e a atualização da matriz de covariância são dados, respectivamente, por

$$h(n) = \frac{P(n-1) u(n)}{1 + u^T(n) P(n-1) u(n)}, \quad (17)$$

$$\hat{\theta}(n) = \hat{\theta}(n-1) + h(n) \left[ y(n) - u^T(n) \hat{\theta}(n-1) \right], \quad (18)$$

$$P(n) = [I - h(n) u^T(n)] P(n-1). \quad (19)$$

#### 4.1.2 MQR com Reinicialização da Matriz $P$

Nesta variante, monitora-se o erro de estimação

$$e(n) = y(n) - u^T(n) \hat{\theta}(n-1), \quad (20)$$

e a matriz  $P$  é reinicializada para  $P = \rho I$ , com  $\rho = 500$ , sempre que  $|e(n)|$  superar um limiar definido pelo projetista e um número mínimo de amostras já tiver sido coletado



(condição que evita reinicializações espúrias durante o transitório inicial). A lógica de decisão implementada é:

$$P(n) = \begin{cases} \rho I, & \text{se } |e(n)| > \delta \text{ e } n > N/10 \\ [I - h(n) u^T(n)] P(n-1), & \text{caso contrário} \end{cases}, \quad (21)$$

em que  $\delta = 0,03$  é o limiar do módulo do erro e  $N$  é o número total de amostras. A condição  $n > N/10$  impede reinicializações durante a fase de convergência inicial, quando o erro é naturalmente elevado.

#### 4.1.3 MQR com Fator de Esquecimento

O fator de esquecimento  $\lambda$ , com  $0 < \lambda < 1$ , é introduzido nas equações do MQR para ponderar exponencialmente as amostras passadas, dando maior relevância às observações mais recentes. As equações modificadas do ganho e da atualização de  $P$  tornam-se

$$h(n) = \frac{P(n-1) u(n)}{\lambda + u^T(n) P(n-1) u(n)}, \quad (22)$$

$$P(n) = \frac{1}{\lambda} [I - h(n) u^T(n)] P(n-1). \quad (23)$$

O fator  $1/\lambda$  na atualização de  $P$  impede que a matriz degenere a zero, mantendo o estimador capaz de rastrear variações paramétricas ao longo do tempo. Nesta atividade, adotou-se  $\lambda = 0,95$  e  $\rho = 100$ .

## 4.2 Resultados e Discussão

### 4.2.1 MQR Padrão

A Figura 6 apresenta a evolução temporal dos quatro parâmetros estimados pelo MQR padrão em comparação com os valores reais. Observa-se que, para  $t < 10$  s, o estimador converge satisfatoriamente para os valores reais da planta inicial. Contudo, quando os parâmetros variam abruptamente em  $t = 10$  s, o rastreamento torna-se extremamente lento ou praticamente nulo.

Esse comportamento é consequência direta da dinâmica da matriz  $P(n)$ : após a convergência dos parâmetros,  $P(n) \rightarrow 0$ , o que faz com que o ganho  $h(n) \approx 0$ . Com isso, as atualizações de  $\hat{\theta}(n)$  cessam efetivamente, tornando o estimador insensível a qualquer variação futura nos parâmetros da planta. Esta é a limitação fundamental do MQR padrão para aplicações com sistemas não estacionários.




Figura 6: MQR padrão – evolução temporal dos parâmetros estimados  $\hat{b}_1$ ,  $\hat{b}_2$ ,  $\hat{a}_1$  e  $\hat{a}_2$  em comparação com os valores reais (linhas pontilhadas). Observa-se a incapacidade de rastreamento após  $t = 10$  s.

#### 4.2.2 MQR com Reinicialização da Matriz $P$

A Figura 7 apresenta os resultados obtidos com a estratégia de reinicialização da matriz  $P$ . Após a variação dos parâmetros em  $t = 10$  s, o erro de estimação  $|e(n)|$  supera o limiar  $\delta$ , disparando a reinicialização e restaurando a capacidade adaptativa do estimador. Os parâmetros convergem para os novos valores da planta de forma consideravelmente mais rápida do que no caso do MQR padrão.

No entanto, a reinicialização introduz picos transitórios mais pronunciados nas estimativas logo após  $t = 10$  s, pois a elevação súbita de  $P$  aumenta temporariamente o ganho  $h(n)$  de forma abrupta. Além disso, o desempenho desse método depende criticamente da escolha do limiar  $\delta$ : valores muito elevados retardam a detecção da mudança, enquanto valores muito baixos disparam reinicializações desnecessárias durante o regime estacionário, prejudicando a precisão da estimação.




Figura 7: MQR com reinicialização de  $P$  ( $\rho = 500$ ,  $\delta = 0,03$ ) – evolução temporal dos parâmetros estimados em comparação com os valores reais.

Nota-se a reconvergência após  $t = 10$  s, com presença de picos transitórios.

#### 4.2.3 MQR com Fator de Esquecimento

A Figura 8 apresenta os resultados do MQR com fator de esquecimento  $\lambda = 0,95$ . Este método demonstrou o melhor desempenho entre os três avaliados. Graças ao fator  $1/\lambda$  na equação de atualização de  $P(n)$ , a matriz não degenera a zero, mantendo um ganho de adaptação positivo ao longo de toda a simulação.

Após a variação paramétrica em  $t = 10$  s, os parâmetros estimados convergem para os novos valores reais de forma rápida e suave, sem os picos transitórios observados na estratégia de reinicialização. Adicionalmente, o fator de esquecimento não exige a configuração de qualquer limiar crítico – o esquecimento das amostras passadas ocorre de maneira automática e contínua, tornando o método mais robusto e simples de implementar em sistemas embarcados.




Figura 8: MQR com fator de esquecimento ( $\lambda = 0,95$ ,  $\rho = 500$ ), evolução temporal dos parâmetros estimados em comparação com os valores reais.

O rastreamento após  $t = 10$  s é rápido e suave.

#### 4.2.4 Síntese Comparativa

A Tabela 4.2.4 resume as características dos três métodos avaliados quanto ao rastreamento da planta variante no tempo.

| Característica            | MQR Padrão  | Reinicialização de P | Fator de Esquecimento |
|---------------------------|-------------|----------------------|-----------------------|
| Convergência inicial      | Rápida      | Rápida               | Rápida                |
| Rastreamento pós-variação | Inexistente | Satisfatório         | Excelente             |
| Picos transitórios        | —           | Elevados             | Baixos                |
| Parâmetros ajustáveis     | $\rho$      | $\rho, \delta$       | $\rho, \lambda$       |
| Complexidade de impl.     | Baixa       | Média                | Baixa                 |

Tabela 3: Comparativo entre as três estratégias de rastreamento do MQR.

Dentre os métodos avaliados, o MQR com fator de esquecimento  $\lambda = 0,95$  mostrou-se superior para o rastreamento de sistemas variantes no tempo. O método de reinicialização de  $P$  também apresentou resultados satisfatórios, porém com maior sensibilidade ao ajuste do limiar  $\delta$  e com picos transitórios mais pronunciados na re-convergência. O MQR padrão, por sua vez, mostrou-se inadequado para este tipo de aplicação, uma vez que sua capacidade adaptativa se esgota após a convergência inicial, impossibilitando o rastreamento de qualquer variação futura nos parâmetros da planta.

## 5 Conclusão

Este laboratório permitiu explorar de forma progressiva o Estimador de Mínimos Quadrados Recursivo em três cenários de complexidade crescente, consolidando tanto os aspectos teóricos quanto as implicações práticas do método.

Na Atividade 1, verificou-se que o parâmetro  $\rho$  exerce influência direta sobre a velocidade de convergência dos parâmetros estimados. Para  $\rho = 0,1$ , o estimador convergiu de forma extremamente lenta, com  $\hat{a}_1$  ainda em transição ao final dos 7s de dados. À medida que  $\rho$  aumenta, a convergência torna-se mais rápida, com ambos os parâmetros estabilizando em poucos instantes para  $\rho \geq 10$ . O modelo identificado com  $\rho = 100$  apresentou o melhor ajuste entre saída experimental e estimada, confirmando a adequação do modelo de primeira ordem para representar o sistema ensaiado.

Na Atividade 2, o ensaio prático com o filtro Sallen-Key demonstrou a capacidade do MQR de operar em tempo real sobre dados experimentais coletados via Arduino Mega. A utilização do fator de esquecimento  $\lambda = 0,95$  com  $\rho = 500$  foi essencial para que o estimador mantivesse capacidade adaptativa ao longo de todo o ensaio, rastreando as mudanças de dinâmica introduzidas pelos comutadores 1 ( $t \approx 17s$ ) e 2 ( $t \approx 32s$ ). A variação clara nos parâmetros estimados entre os três regimes operacionais confirmou que o algoritmo acompanhou adequadamente as alterações do sistema.

Na Atividade 3, a comparação entre as três estratégias de rastreamento evidenciou de forma clara as limitações e vantagens de cada abordagem. O MQR padrão mostrou-se inadequado para sistemas variantes no tempo: após a convergência inicial, a matriz  $P(n) \rightarrow 0$  e o ganho  $h(n) \approx 0$ , travando as atualizações e impossibilitando qualquer rastreamento após  $t = 10s$ . A reinicialização de  $P$  restaurou a capacidade adaptativa do estimador, porém com picos transitórios pronunciados e desempenho sensível à escolha do limiar  $\delta$ . O MQR com fator de esquecimento  $\lambda = 0,95$  apresentou o melhor desempenho, com reconvergência rápida e suave após a variação paramétrica, sem necessidade de ajuste de limiares adicionais.

De forma geral, os resultados obtidos ao longo das três atividades são consistentes entre si: a mesma lógica que explica a influência de  $\rho$  na velocidade de convergência da Atividade 1 fundamenta a necessidade de manter  $P$  com norma não nula nas Atividades 2 e 3. O MQR com fator de esquecimento configura-se, portanto, como a abordagem mais adequada para aplicações práticas com sistemas variantes no tempo, combinando simplicidade de implementação, adaptação contínua e robustez a variações paramétricas imprevisíveis.